PEDRO HERRERA DIAZ

MATERIA: INTRODUCCION A LA CIENCIA DE DATOS

NOMBRE DEL PROFESOR

JAIME ALEJANDRO ROMERO SIERRA

20/10/2025

https://github.com/user-attachments/files/23013583/ObesityDataSet_raw_and_data_sinthetic.csv

Esta base de datos contiene información sobre la obesidad

En esta base de datos encontramos diferentes columnas, como lo son genero, edad, altura, peso, antecedentes, familiares con sobre peso.

GENERO: masculino o femenino

Edad:

Altura:

Peso:

Antecedentes:

Familiares con sobre peso:

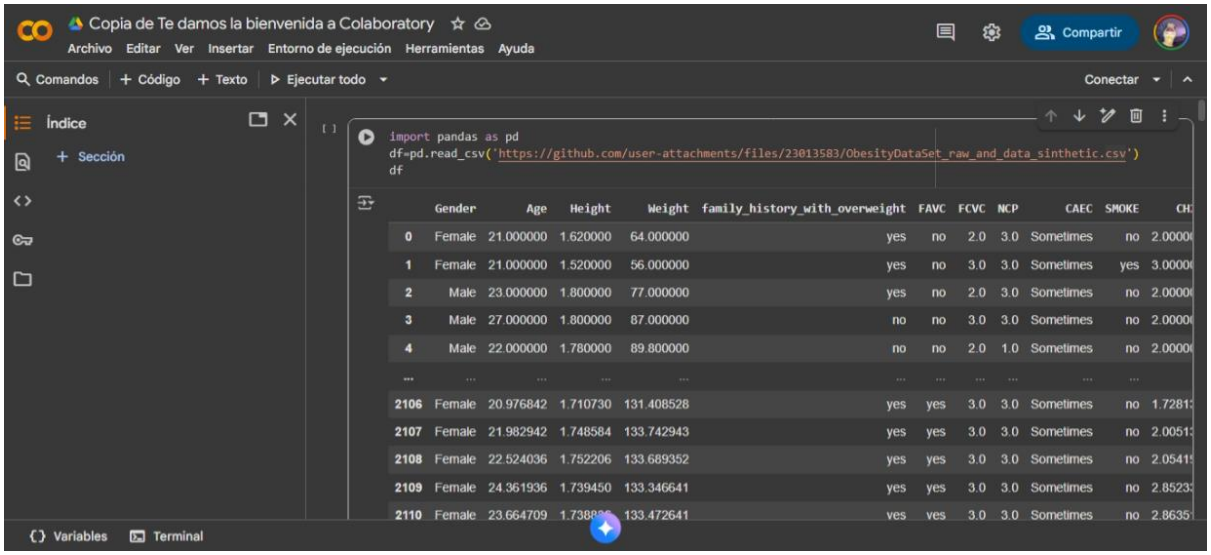
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
import pandas as pd
df=pd.read_csv('https://github.com/user-attachments/files/23013583/ObesityDataSet_raw_and_data_sinthetic.csv')
df
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE CH
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no 2.0000
1 Female 21.000000 1.520000 56.000000 yes no 3.0 3.0 Sometimes yes 3.0000
2 Male 23.000000 1.800000 77.000000 yes no 2.0 3.0 Sometimes no 2.0000
3 Male 27.000000 1.800000 87.000000 no no 3.0 3.0 Sometimes no 2.0000
4 Male 22.000000 1.780000 89.800000 no no 2.0 1.0 Sometimes no 2.0000
2106 Female 20.976842 1.710730 131.408528 yes yes 3.0 3.0 Sometimes no 1.7281
2107 Female 21.982942 1.748584 133.742943 yes yes 3.0 3.0 Sometimes no 2.0513
2108 Female 22.524036 1.752206 133.689352 yes yes 3.0 3.0 Sometimes no 2.0541
2109 Female 24.361936 1.739450 133.346641 yes yes 3.0 3.0 Sometimes no 2.8523
2110 Female 23.664709 1.738 133.472641 yes yes 3.0 3.0 Sometimes no 2.8635
Variables Terminal

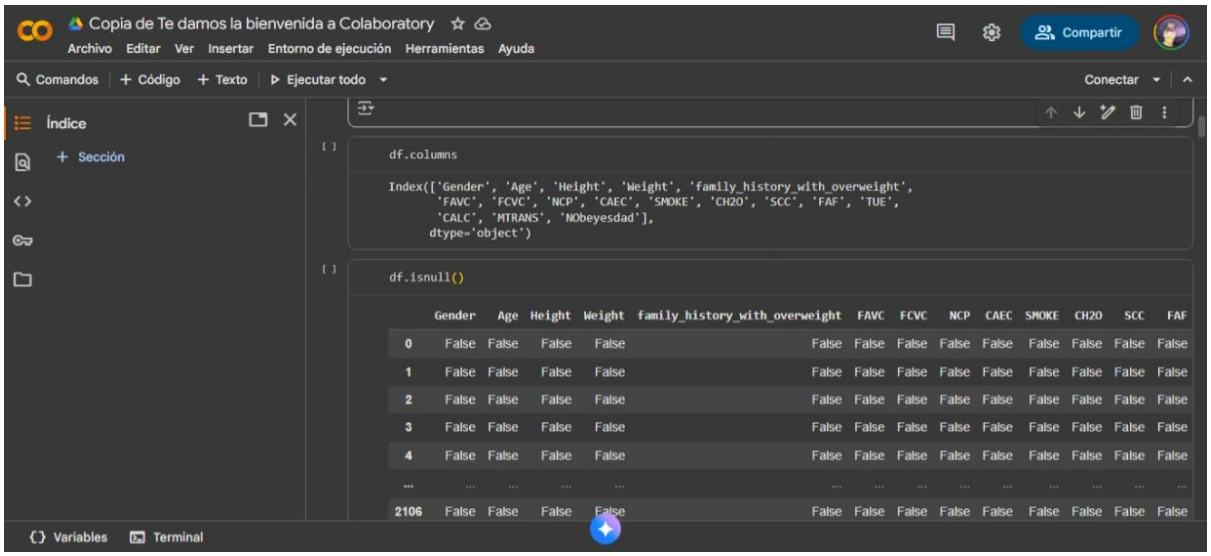
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df.columns
Index(['Gender', 'Age', 'Height', 'Weight', 'family_history_with_overweight',
'FAVC', 'FCVC', 'NCP', 'CAEC', 'SMOKE', 'CH2O', 'SCC', 'FAF', 'TUE',
'CALC', 'MTRANS', 'NObeyesdad'],
dtype='object')
df.isnull()
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE CH2O SCC FAF
0 False False False False False False False False False False False False
1 False False False False False False False False False False False False
2 False False False False False False False False False False False False
3 False False False False False False False False False False False False
4 False False False False False False False False False False False False
2106 False False False False False False False False False False False False
Variables Terminal

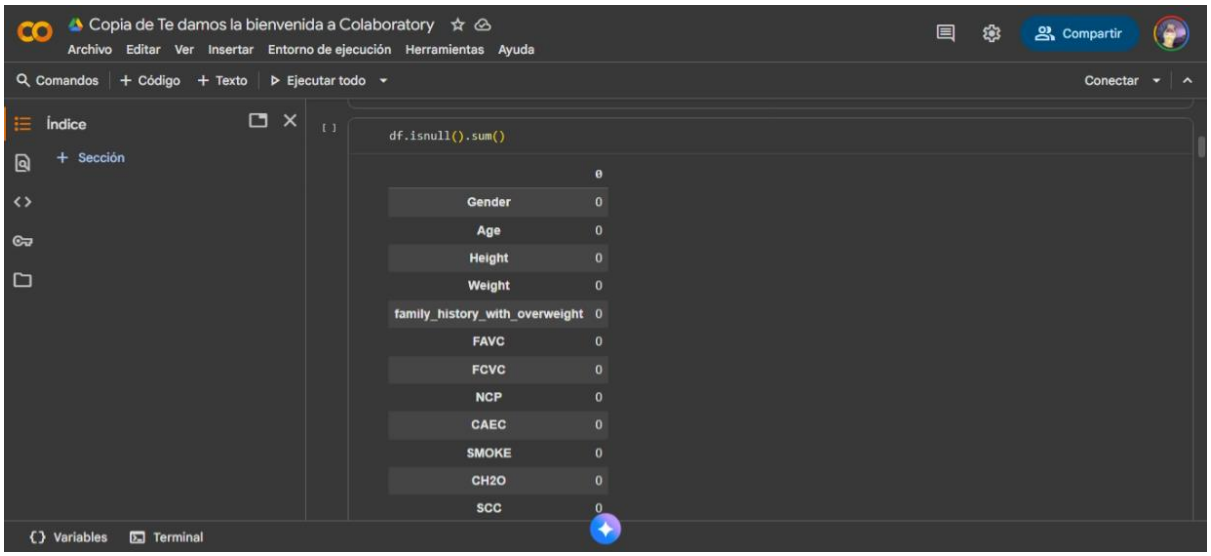
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df.isnull().sum()
0
Gender 0
Age 0
Height 0
Weight 0
family_history_with_overweight 0
FAVC 0
FCVC 0
NCP 0
CAEC 0
SMOKE 0
CH2O 0
SCC 0
Variables Terminal

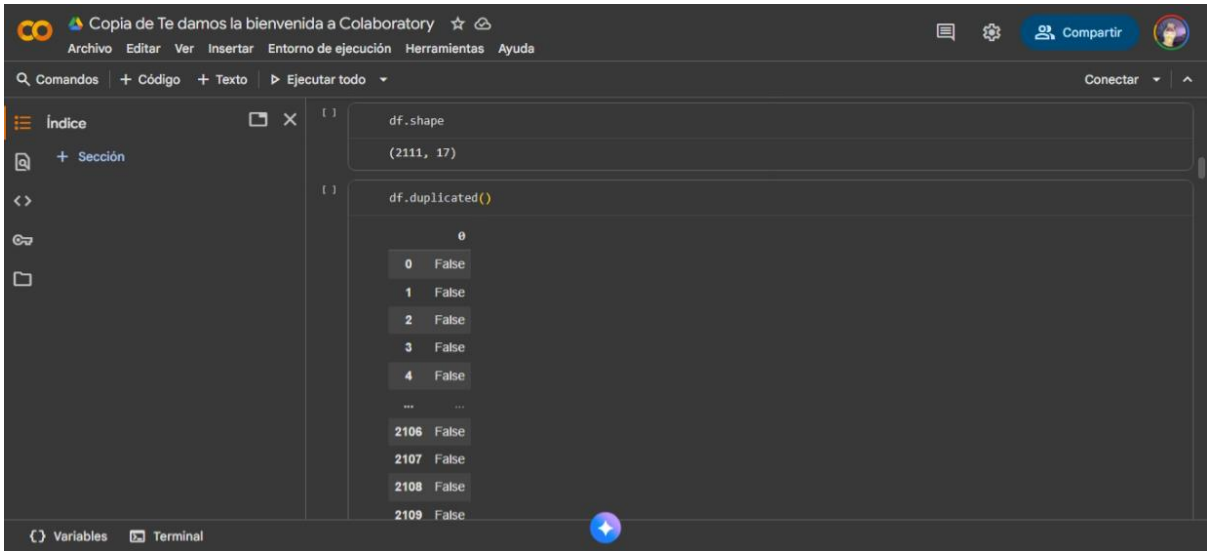
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df.shape
(2111, 17)
df.duplicated()
0
0 False
1 False
2 False
3 False
4 False
2106 False
2107 False
2108 False
2109 False
Variables Terminal

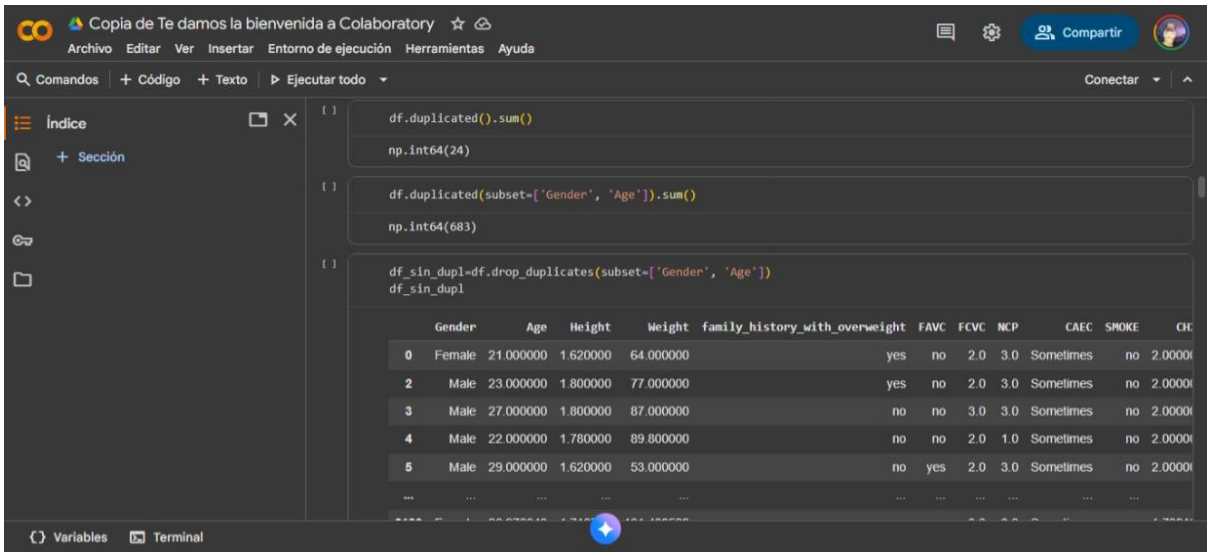
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df.duplicated().sum()
np.int64(24)
df.duplicated(subset=['Gender', 'Age']).sum()
np.int64(683)
df_sin_dupl=df.drop_duplicates(subset=['Gender', 'Age'])
df_sin_dupl
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no
2 Male 23.000000 1.800000 77.000000 yes no 2.0 3.0 Sometimes no
3 Male 27.000000 1.800000 87.000000 no no 3.0 3.0 Sometimes no
4 Male 22.000000 1.780000 89.800000 no no 2.0 1.0 Sometimes no
5 Male 29.000000 1.620000 53.000000 no yes 2.0 3.0 Sometimes no
Variables Terminal

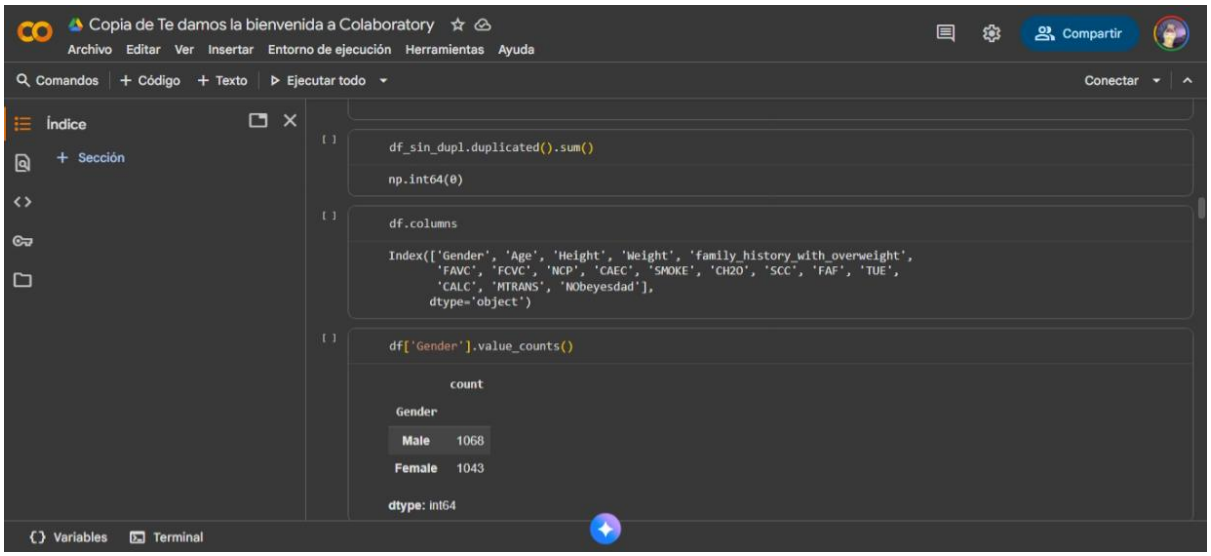
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df_sin_dupl.duplicated().sum()
np.int64(0)
df.columns
Index(['Gender', 'Age', 'Height', 'Weight', 'family_history_with_overweight',
'FAVC', 'FCVC', 'NCP', 'CAEC', 'SMOKE', 'CH2O', 'SCC', 'FAF', 'TUE',
'CALC', 'MTRANS', 'NObeyesdad'],
dtype='object')
df['Gender'].value_counts()
count
Gender
Male 1068
Female 1043
dtype: int64
Variables Terminal

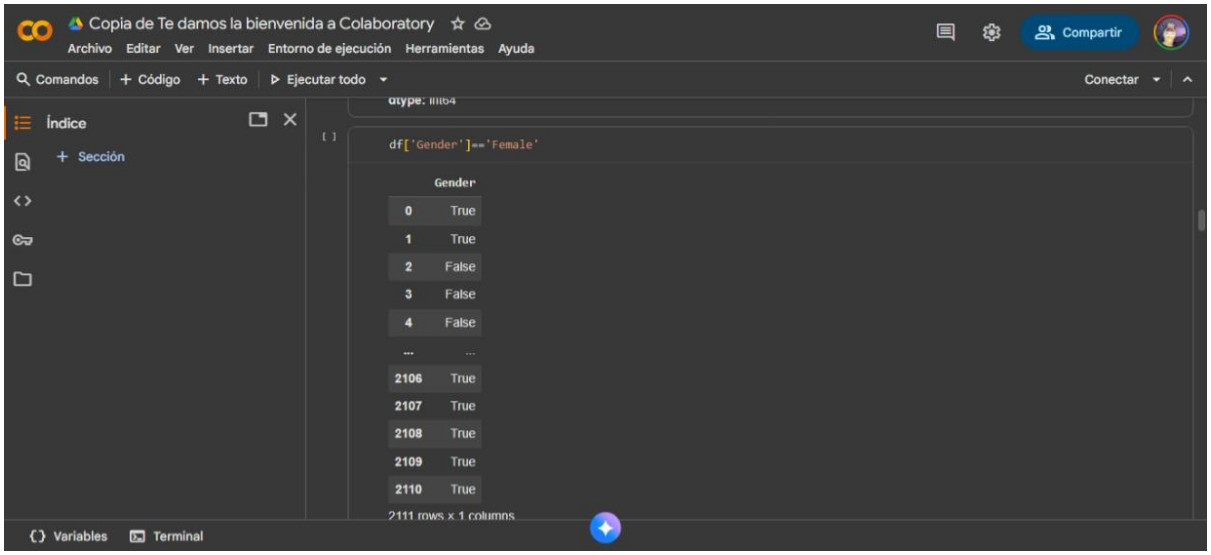
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
dtype: int64
df['Gender']=='Female'
Gender
0 True
1 True
2 False
3 False
4 False
2106 True
2107 True
2108 True
2109 True
2110 True
2111 rows x 1 columns
Variables Terminal

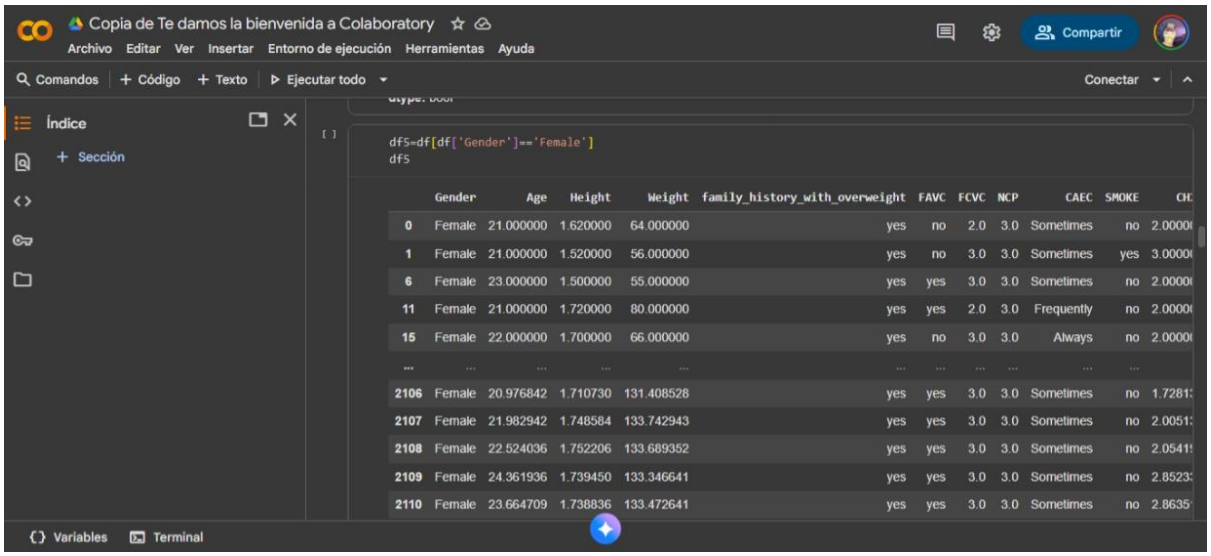
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df5=df[df['Gender']=='Female']
df5
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no
1 Female 21.000000 1.520000 56.000000 yes no 3.0 3.0 Sometimes yes
6 Female 23.000000 1.500000 55.000000 yes yes 3.0 3.0 Sometimes no
11 Female 21.000000 1.720000 80.000000 yes yes 2.0 3.0 Frequently no
15 Female 22.000000 1.700000 66.000000 yes no 3.0 3.0 Always no
2106 Female 20.976842 1.710730 131.408528 yes yes 3.0 3.0 Sometimes no
2107 Female 21.982942 1.748584 133.742943 yes yes 3.0 3.0 Sometimes no
2108 Female 22.524036 1.752206 133.689352 yes yes 3.0 3.0 Sometimes no
2109 Female 24.361936 1.739450 133.346641 yes yes 3.0 3.0 Sometimes no
2110 Female 23.664709 1.738836 133.472641 yes yes 3.0 3.0 Sometimes no
Variables Terminal

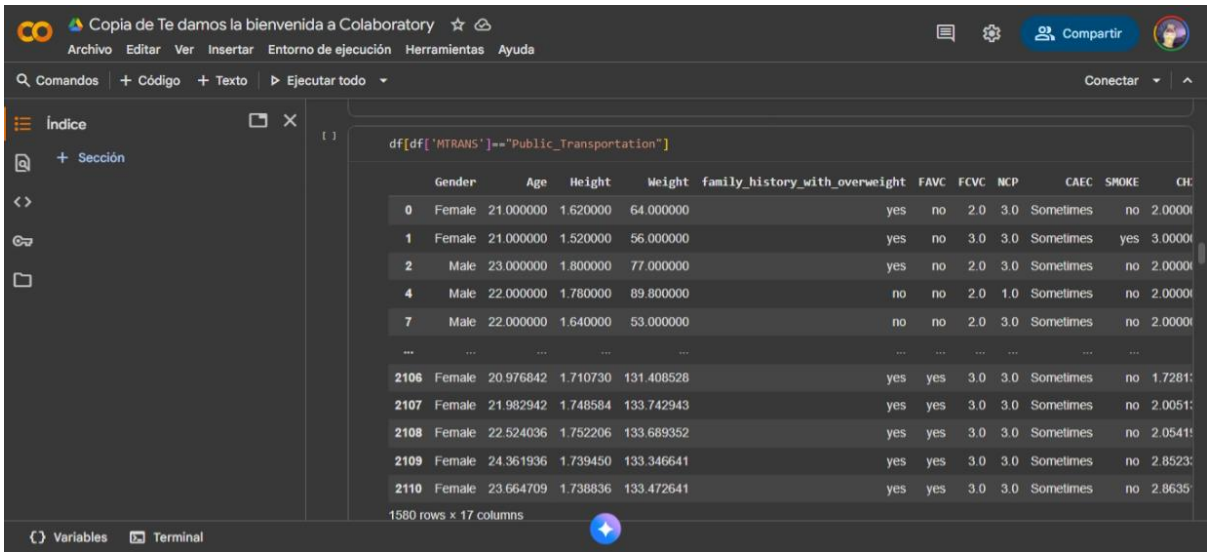
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df[df['MTRANS']=="Public_Transportation"]
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no
1 Female 21.000000 1.520000 56.000000 yes no 3.0 3.0 Sometimes yes
2 Male 23.000000 1.800000 77.000000 yes no 2.0 3.0 Sometimes no
4 Male 22.000000 1.780000 89.800000 no no 2.0 1.0 Sometimes no
7 Male 22.000000 1.640000 53.000000 no no 2.0 3.0 Sometimes no
2106 Female 20.976842 1.710730 131.408528 yes yes 3.0 3.0 Sometimes no
2107 Female 21.982942 1.748584 133.742943 yes yes 3.0 3.0 Sometimes no
2108 Female 22.524036 1.752206 133.689352 yes yes 3.0 3.0 Sometimes no
2109 Female 24.361936 1.739450 133.346641 yes yes 3.0 3.0 Sometimes no
2110 Female 23.664709 1.738836 133.472641 yes yes 3.0 3.0 Sometimes no
1580 rows x 17 columns
Variables Terminal

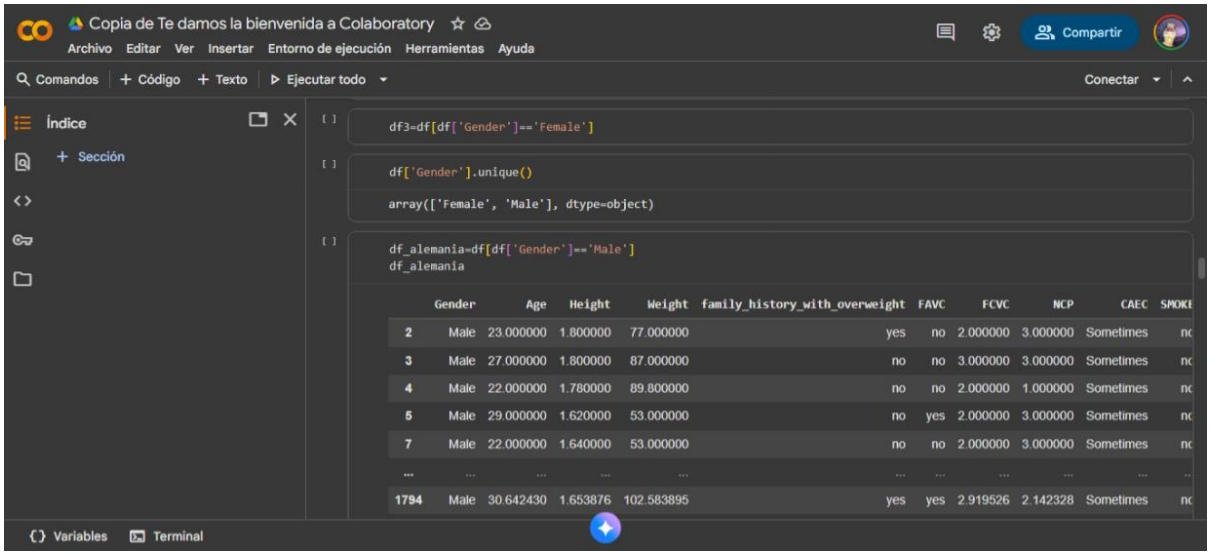
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df3=df[df['Gender']=='Female']
df['Gender'].unique()
array(['Female', 'Male'], dtype=object)
df_alemania=df[df['Gender']=='Male']
df_alemania
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE
2 Male 23.000000 1.800000 77.000000 yes no 2.000000 3.000000 Sometimes no
3 Male 27.000000 1.800000 87.000000 no no 3.000000 3.000000 Sometimes no
4 Male 22.000000 1.780000 89.800000 no no 2.000000 1.000000 Sometimes no
5 Male 29.000000 1.620000 53.000000 no yes 2.000000 3.000000 Sometimes no
7 Male 22.000000 1.640000 53.000000 no no 2.000000 3.000000 Sometimes no
1794 Male 30.642430 1.653876 102.583895 yes yes 2.919526 2.142328 Sometimes no
Variables Terminal

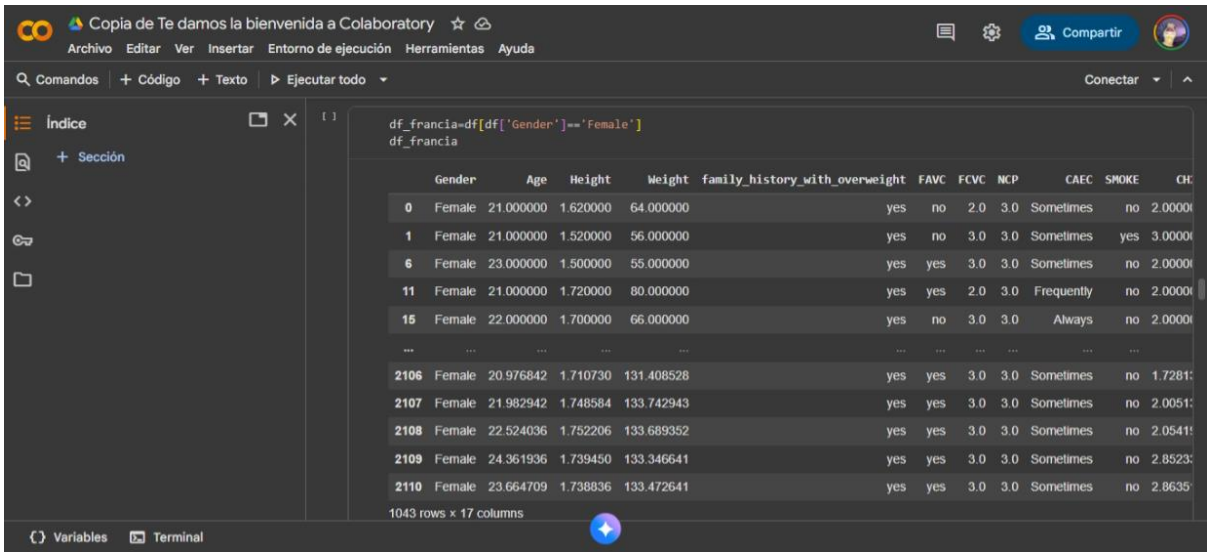
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df_francia=df[df['Gender']=='Female']
df_francia
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no
1 Female 21.000000 1.520000 56.000000 yes no 3.0 3.0 Sometimes yes
6 Female 23.000000 1.500000 55.000000 yes yes 3.0 3.0 Sometimes no
11 Female 21.000000 1.720000 80.000000 yes yes 2.0 3.0 Frequently no
15 Female 22.000000 1.700000 66.000000 yes no 3.0 3.0 Always no
2106 Female 20.976842 1.710730 131.408528 yes yes 3.0 3.0 Sometimes no
2107 Female 21.982942 1.748584 133.742943 yes yes 3.0 3.0 Sometimes no
2108 Female 22.524036 1.752206 133.689352 yes yes 3.0 3.0 Sometimes no
2109 Female 24.361936 1.739450 133.346641 yes yes 3.0 3.0 Sometimes no
2110 Female 23.664709 1.738836 133.472641 yes yes 3.0 3.0 Sometimes no
1043 rows × 17 columns
Variables Terminal

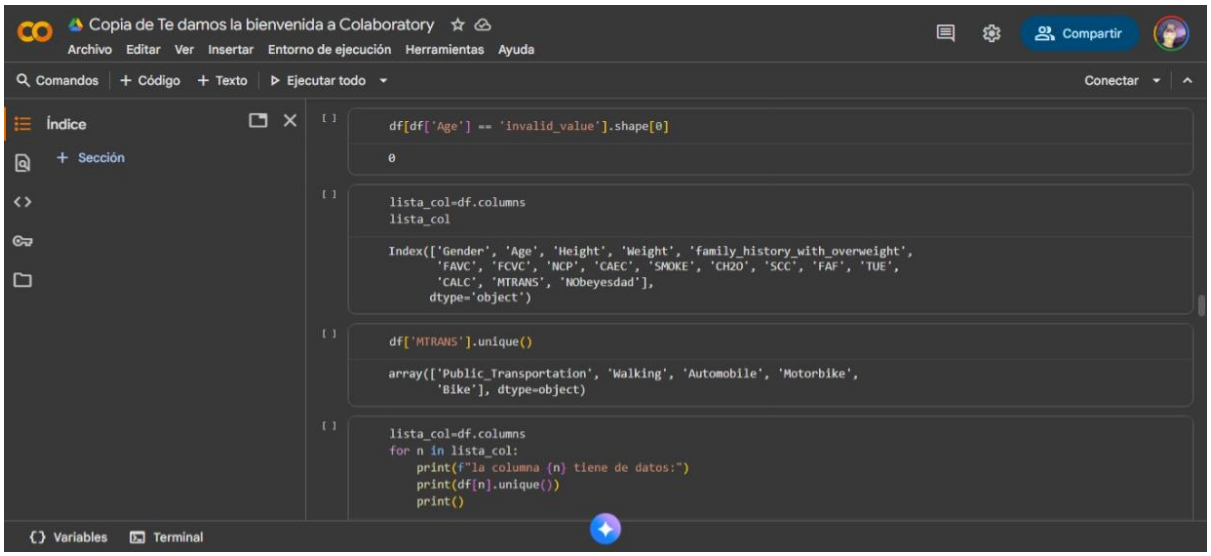
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df[df['Age'] == 'invalid_value'].shape[0]
0
lista_col=df.columns
lista_col
Index(['Gender', 'Age', 'Height', 'Weight', 'family_history_with_overweight',
'FAVC', 'FCVC', 'NCP', 'CAEC', 'SMOKE', 'CH2O', 'SCC', 'FAF', 'TUE',
'CALC', 'MTRANS', 'NObeyesdad'],
dtype='object')
df['MTRANS'].unique()
array(['Public_Transportation', 'Walking', 'Automobile', 'Motorbike',
'Bike'], dtype=object)
lista_col=df.columns
for n in lista_col:
print(f"la columna {n} tiene de datos:")
print(df[n].unique())
print()
Variables Terminal

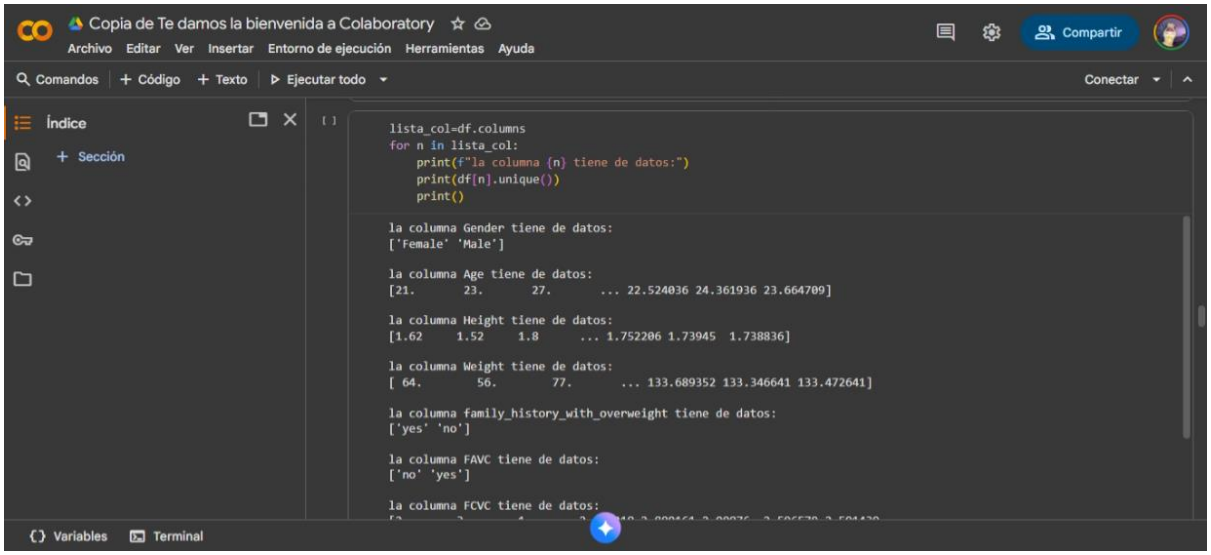
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
lista_col=df.columns
for n in lista_col:
print(f"la columna {n} tiene de datos:")
print(df[n].unique())
print()
la columna Gender tiene de datos:
['Female' 'Male']
la columna Age tiene de datos:
[21. 23. 27. ... 22.524036 24.361936 23.664709]
la columna Height tiene de datos:
[1.62 1.52 1.8 ... 1.752206 1.73945 1.738836]
la columna Weight tiene de datos:
[64. 56. 77. ... 133.689352 133.346641 133.472641]
la columna family_history_with_overweight tiene de datos:
['yes' 'no']
la columna FAVC tiene de datos:
['no' 'yes']
la columna FCVC tiene de datos:
Variables Terminal

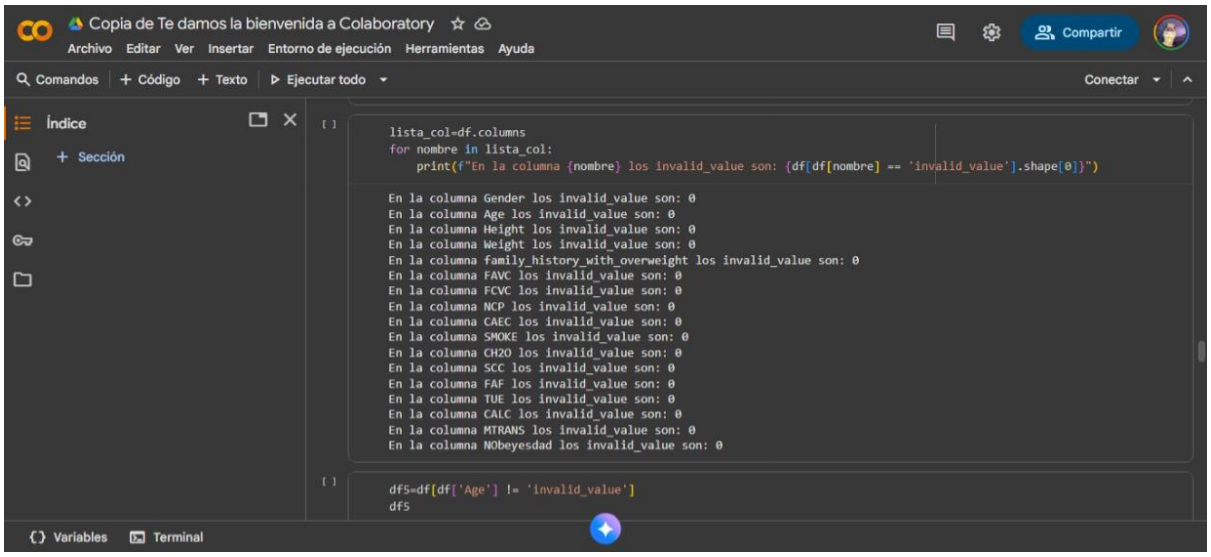
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
lista_col=df.columns
for nombre in lista_col:
print(f"En la columna {nombre} los invalid_value son: {df[df[nombre] == 'invalid_value'].shape[0]}")
En la columna Gender los invalid_value son: 0
En la columna Age los invalid_value son: 0
En la columna Height los invalid_value son: 0
En la columna Weight los invalid_value son: 0
En la columna family_history_with_overweight los invalid_value son: 0
En la columna FAVC los invalid_value son: 0
En la columna FCVC los invalid_value son: 0
En la columna NCP los invalid_value son: 0
En la columna CAEC los invalid_value son: 0
En la columna SMOKE los invalid_value son: 0
En la columna CH2O los invalid_value son: 0
En la columna SCC los invalid_value son: 0
En la columna FAF los invalid_value son: 0
En la columna TUE los invalid_value son: 0
En la columna CALC los invalid_value son: 0
En la columna MTRANS los invalid_value son: 0
En la columna NObeyesdad los invalid_value son: 0
df5=df[df['Age'] != 'invalid_value']
df5
Variables Terminal

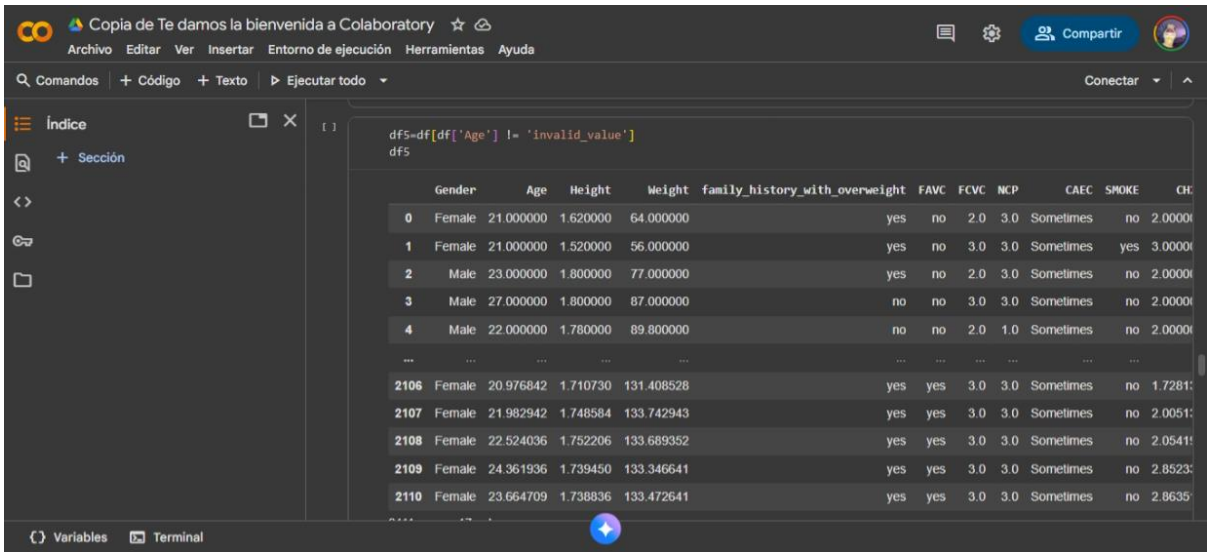
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df5=df[df['Age'] != 'invalid_value']
df5
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE CH
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no 2.0000
1 Female 21.000000 1.520000 56.000000 yes no 3.0 3.0 Sometimes yes 3.0000
2 Male 23.000000 1.800000 77.000000 yes no 2.0 3.0 Sometimes no 2.0000
3 Male 27.000000 1.800000 87.000000 no no 3.0 3.0 Sometimes no 2.0000
4 Male 22.000000 1.780000 89.800000 no no 2.0 1.0 Sometimes no 2.0000
2106 Female 20.976842 1.710730 131.408528 yes yes 3.0 3.0 Sometimes no 1.7281
2107 Female 21.982942 1.748584 133.742943 yes yes 3.0 3.0 Sometimes no 2.0051
2108 Female 22.524036 1.752206 133.689352 yes yes 3.0 3.0 Sometimes no 2.0541
2109 Female 24.361936 1.739450 133.346641 yes yes 3.0 3.0 Sometimes no 2.8523
2110 Female 23.664709 1.738836 133.472641 yes yes 3.0 3.0 Sometimes no 2.8635
Variables Terminal

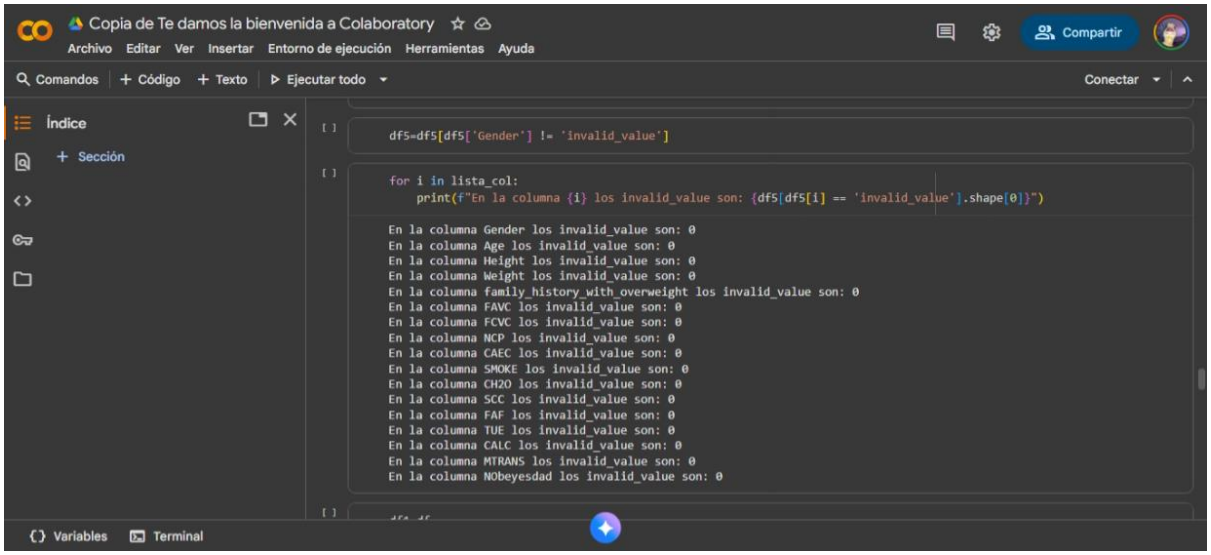
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df5=df5[df5['Gender'] != 'invalid_value']
for i in lista_col:
print(f"En la columna {i} los invalid_value son: {df5[df5[i] == 'invalid_value'].shape[0]}")
En la columna Gender los invalid_value son: 0
En la columna Age los invalid_value son: 0
En la columna Height los invalid_value son: 0
En la columna Weight los invalid_value son: 0
En la columna family_history_with_overweight los invalid_value son: 0
En la columna FAVC los invalid_value son: 0
En la columna FCVC los invalid_value son: 0
En la columna NCP los invalid_value son: 0
En la columna CAEC los invalid_value son: 0
En la columna SMOKE los invalid_value son: 0
En la columna CH2O los invalid_value son: 0
En la columna SCC los invalid_value son: 0
En la columna FAF los invalid_value son: 0
En la columna TUE los invalid_value son: 0
En la columna CALC los invalid_value son: 0
En la columna MTRANS los invalid_value son: 0
En la columna NObeyesdad los invalid_value son: 0
Variables Terminal

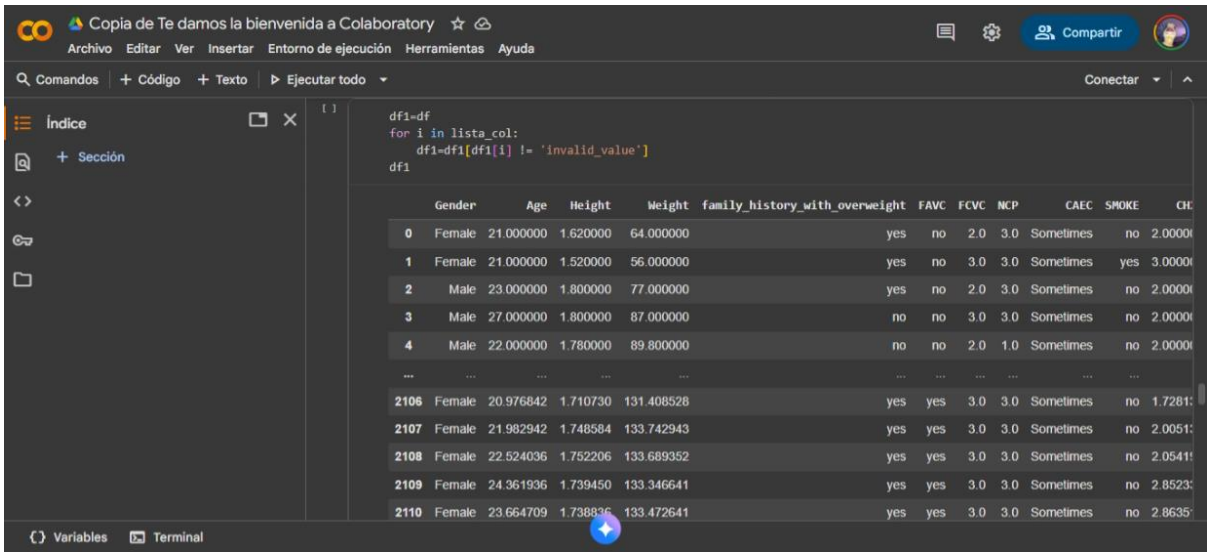
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df1=df
for i in lista_col:
df1=df1[df1[i] != 'invalid_value']
df1
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE CH
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no 2.0000
1 Female 21.000000 1.520000 56.000000 yes no 3.0 3.0 Sometimes yes 3.0000
2 Male 23.000000 1.800000 77.000000 yes no 2.0 3.0 Sometimes no 2.0000
3 Male 27.000000 1.800000 87.000000 no no 3.0 3.0 Sometimes no 2.0000
4 Male 22.000000 1.780000 89.800000 no no 2.0 1.0 Sometimes no 2.0000
2106 Female 20.976842 1.710730 131.408528 yes yes 3.0 3.0 Sometimes no 1.7281
2107 Female 21.982942 1.748584 133.742943 yes yes 3.0 3.0 Sometimes no 2.0051
2108 Female 22.524036 1.752206 133.689352 yes yes 3.0 3.0 Sometimes no 2.0541
2109 Female 24.361936 1.739450 133.346641 yes yes 3.0 3.0 Sometimes no 2.8523
2110 Female 23.664709 1.738836 133.472641 yes yes 3.0 3.0 Sometimes no 2.8635
Variables Terminal

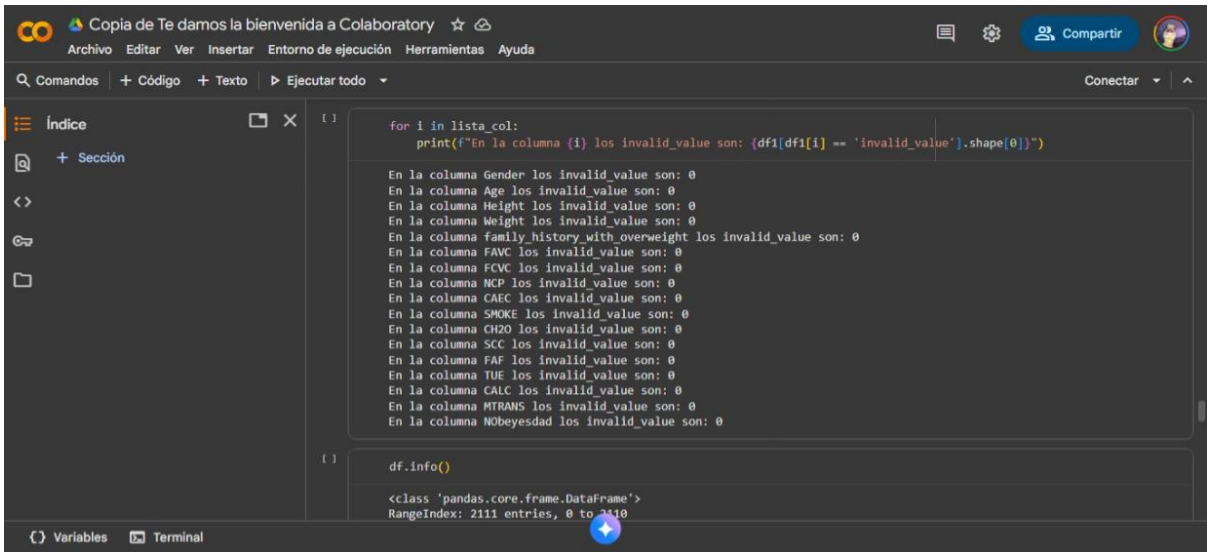
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
for i in lista_col:
print(f"En la columna {i} los invalid_value son: {df1[df1[i] == 'invalid_value'].shape[0]}")
En la columna Gender los invalid_value son: 0
En la columna Age los invalid_value son: 0
En la columna Height los invalid_value son: 0
En la columna Weight los invalid_value son: 0
En la columna family_history_with_overweight los invalid_value son: 0
En la columna FAVC los invalid_value son: 0
En la columna FCVC los invalid_value son: 0
En la columna NCP los invalid_value son: 0
En la columna CAEC los invalid_value son: 0
En la columna SMOKE los invalid_value son: 0
En la columna CH2O los invalid_value son: 0
En la columna SCC los invalid_value son: 0
En la columna FAF los invalid_value son: 0
En la columna TUE los invalid_value son: 0
En la columna CALC los invalid_value son: 0
En la columna MTRANS los invalid_value son: 0
En la columna NObeyesdad los invalid_value son: 0
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2111 entries, 0 to 2110
Variables Terminal

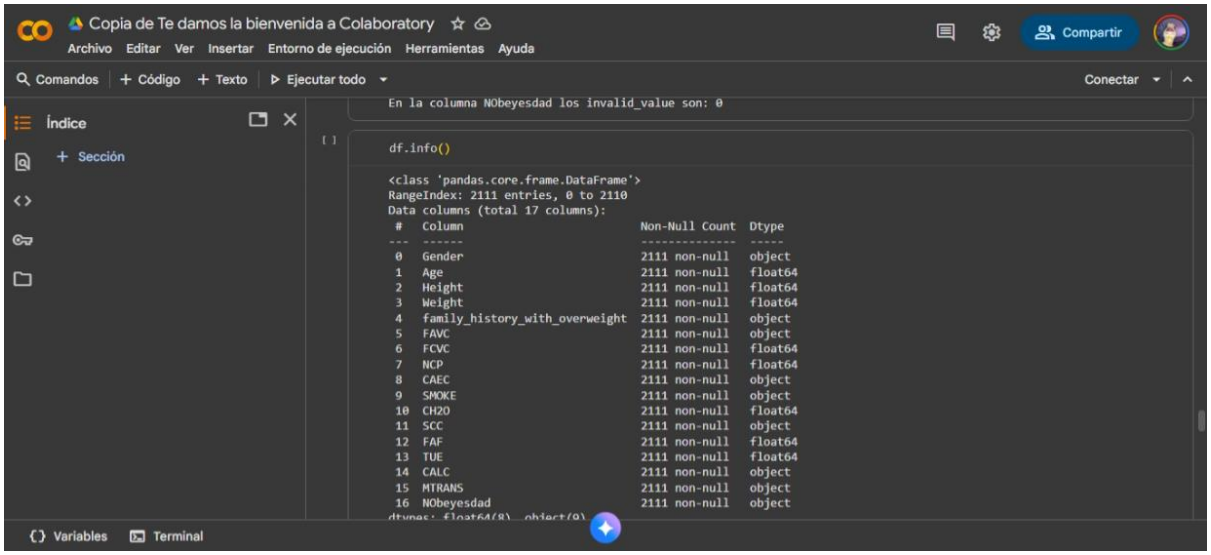
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
En la columna NObeyesdad los invalid_value son: 0
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2111 entries, 0 to 2110
Data columns (total 17 columns):
Column Non-Null Count Dtype
0 Gender 2111 non-null object
1 Age 2111 non-null float64
2 Height 2111 non-null float64
3 Weight 2111 non-null float64
4 family_history_with_overweight 2111 non-null object
5 FAVC 2111 non-null object
6 FCVC 2111 non-null float64
7 NCP 2111 non-null float64
8 CAEC 2111 non-null object
9 SMOKE 2111 non-null object
10 CH2O 2111 non-null float64
11 SCC 2111 non-null object
12 FAF 2111 non-null float64
13 TUE 2111 non-null float64
14 CALC 2111 non-null object
15 MTRANS 2111 non-null object
16 NObeyesdad 2111 non-null object
Variables Terminal

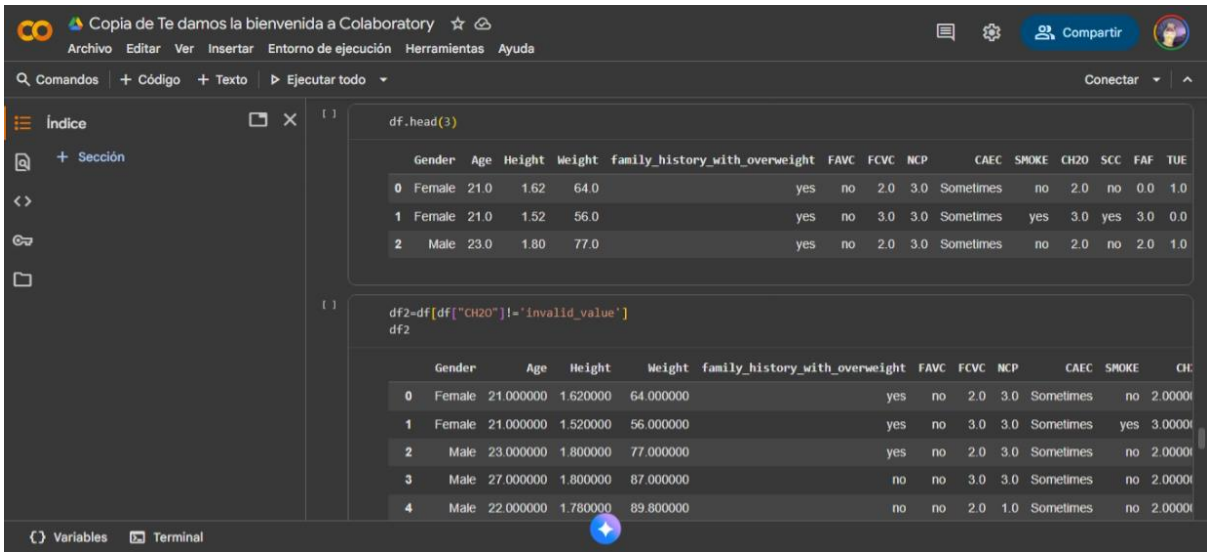
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df.head(3)
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE CH2O SCC FAF TUE
0 Female 21.0 1.62 64.0 yes no 2.0 3.0 Sometimes no 2.0 no 0.0 1.0
1 Female 21.0 1.52 56.0 yes no 3.0 3.0 Sometimes yes 3.0 yes 3.0 0.0
2 Male 23.0 1.80 77.0 yes no 2.0 3.0 Sometimes no 2.0 no 2.0 1.0
df2=df[df["CH2O"]!='invalid_value']
df2
Gender Age Height Weight family_history_with_overweight FAVC FCVC NCP CAEC SMOKE
0 Female 21.000000 1.620000 64.000000 yes no 2.0 3.0 Sometimes no
1 Female 21.000000 1.520000 56.000000 yes no 3.0 3.0 Sometimes yes
2 Male 23.000000 1.800000 77.000000 yes no 2.0 3.0 Sometimes no
3 Male 27.000000 1.800000 87.000000 no no 3.0 3.0 Sometimes no
4 Male 22.000000 1.780000 89.800000 no no 2.0 1.0 Sometimes no
Variables Terminal

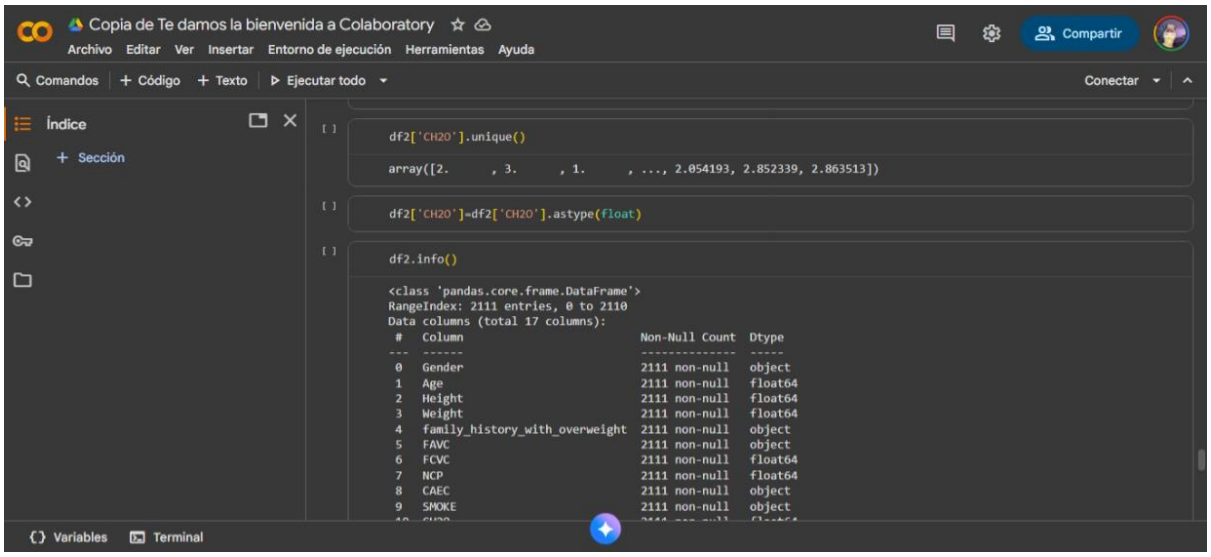
Copia de Te damos la bienvenida a Colaboratory
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Compartir
Comandos + Código + Texto Ejecutar todo
Conectar
Índice
+ Sección
df2['CH2O'].unique()
array([2. , 3. , 1. , ..., 2.054193, 2.852339, 2.863513])
df2['CH2O']=df2['CH2O'].astype(float)
df2.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2111 entries, 0 to 2110
Data columns (total 17 columns):
Column Non-Null Count Dtype
0 Gender 2111 non-null object
1 Age 2111 non-null float64
2 Height 2111 non-null float64
3 Weight 2111 non-null float64
4 family_history_with_overweight 2111 non-null object
5 FAVC 2111 non-null object
6 FCVC 2111 non-null float64
7 NCP 2111 non-null float64
8 CAEC 2111 non-null object
9 SMOKE 2111 non-null object
Variables Terminal

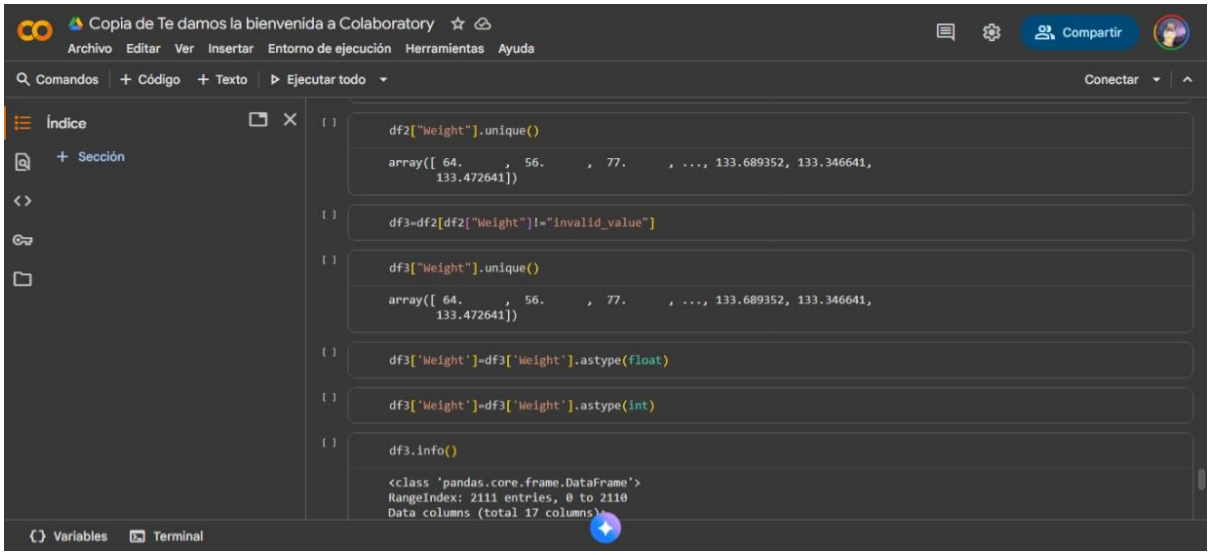

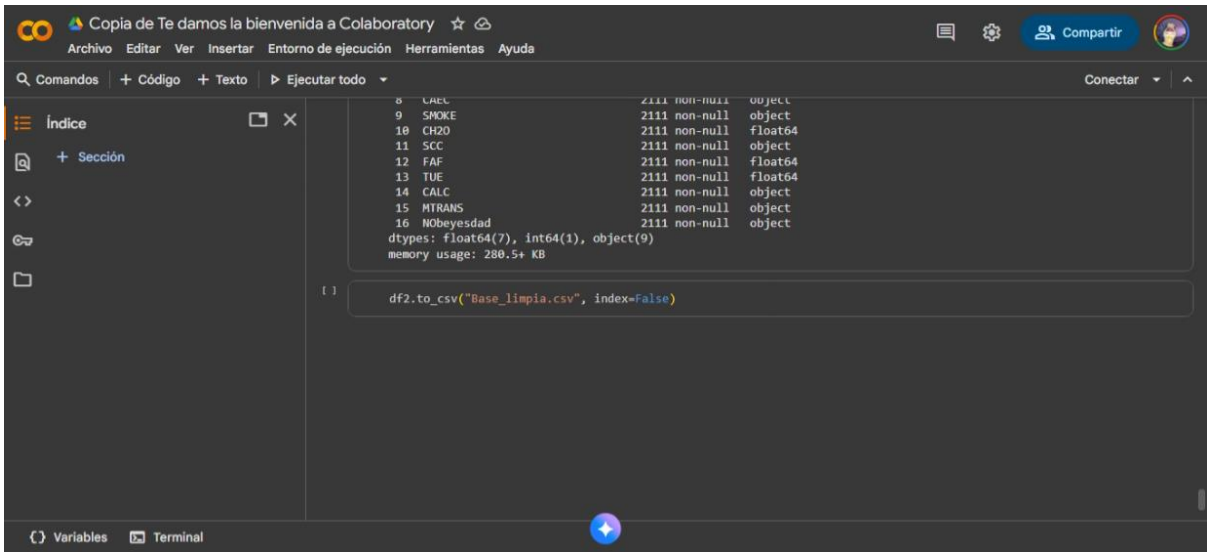

Conclusión

La base de datos no estuvo complicada, ya que en la mayoría esta en una forma donde yo puede trabajar sin ningún problema.